

Informe final: Magnitud de eventos sísmicos USGS 2024

Primer Semestre 2026

1. Pregunta y contexto

Los sismos constituyen una amenaza natural relevante por sus posibles efectos humanos, materiales y territoriales [3]. Su magnitud resume el tamaño instrumental del evento, pero el valor publicado forma parte de un catálogo construido a partir de redes de estaciones, métodos de cálculo y procedimientos de revisión. Por ello, además de describir la distribución de magnitudes, resulta estadísticamente pertinente examinar cómo esta se relaciona con la profundidad, la ubicación y las características del registro.

El presente estudio utiliza el *USGS Earthquake Catalog*, fuente pública y estandarizada del U.S. Geological Survey [1]. El catálogo permite conectar una pregunta de interés geofísico con variables observables y comparables entre eventos. El análisis se concentra en asociaciones dentro de la muestra y reconoce que las variables técnicas describen el proceso de registro; no se interpretan como mecanismos físicos causales del sismo.

En base a la problemática expuesta, se plantea la siguiente pregunta de investigación: **¿Cómo se asocia la magnitud de los eventos sísmicos registrados por USGS durante 2024 con su profundidad, localización geográfica y características técnicas del registro?**

La variable respuesta es la magnitud reportada, *mag*. El enfoque es *descriptivo-explicativo*: se estiman asociaciones y diferencias promedio dentro del catálogo observado, no se predicen terremotos futuros ni se construye un sistema operacional de alerta. La pregunta es abordable mediante regresión lineal múltiple porque la respuesta es numérica y los predictores combinan variables continuas y categóricas representables mediante indicadores. Se utiliza una secuencia de modelos para evaluar, de manera ordenada, el aporte de cada bloque de variables.

La interpretación de fondo se centra en cómo varía la magnitud reportada según profundidad, posición geográfica y características técnicas del registro sísmico. Una limitación central es que la muestra está truncada a eventos con magnitud al menos 4, por lo que las conclusiones no se extrapolan a sismos menores ni al proceso sísmico completo.

2. Fuente, datos y ética

La fuente del dataset empleado es el *USGS Earthquake Catalog*, catálogo oficial y público del *U.S. Geological Survey* (USGS, Servicio Geológico de Estados Unidos) [1], el cual, a través de su extensa red de estaciones, el USGS registra continuamente miles de eventos tectónicos, capturando detalladamente sus coordenadas espaciales, características físicas y los parámetros de la estación que los detecta.

La unidad de observación es un evento sísmico registrado durante 2024 con *mag* mayor o igual a 4. La

API permite otras consultas, por lo que este umbral es una decisión metodológica de alcance y no una restricción técnica de la fuente. El corte concentra el estudio en un subconjunto homogéneo y manejable de eventos moderados o mayores, pero trunca la distribución de la respuesta y acumula observaciones cerca de 4. En consecuencia, no se supone que el filtro garantice mediciones sin error y las conclusiones no se extrapolan a sismos menores ni al proceso sísmico completo.

Los detalles sobre los componentes de esta base de datos, incluyendo la tipología y el rol de cada variable analizada, se presentan a continuación en la Tabla 1.

Tabla 1
Estructura de variables principales en la base analítica

Variable	Tipo	Rol	Justificación de uso
mag	Numérica	Respuesta	Magnitud reportada del evento sísmico.
depth	Numérica	Predictor	Profundidad en km; el modelo final usa su término lineal y cuadrático.
log_depth_plus_1	Numérica	Sensibilidad	Alternativa comparada formalmente con depth y depth ² .
latitude, longitude	Numéricas	Predictores	Coordenadas del epicentro; controlan diferencias geográficas amplias.
nst	Numérica	Técnica	Número de estaciones; se modela como $\log(\text{nst} + 1)$.
gap	Numérica	Técnica	Brecha azimutal; se modela como $\log(\text{gap} + 1)$ y su cuadrado.
dmin	Numérica	Técnica	Distancia mínima; se modela como $\log(\text{dmin} + 1)$ y su cuadrado.
rms	Numérica	Técnica	Raíz del error cuadrático medio de los residuos de tiempo de viaje.
magType, net	Catóricas	Indicadores	Método de magnitud y código de la red que reporta el evento.
region_from_place	Catórica derivada	Apoyo descriptivo	Se agrega para resumir el texto place en una categoría geográfica interpretable. No reemplaza latitud-longitud, pero ayuda a describir regiones frecuentes y posibles diferencias por zona.

La selección no se basa únicamente en correlaciones bivariadas. Combina tres criterios: relación directa con la pregunta, interpretación dentro del catálogo y disponibilidad suficiente. Profundidad y coordenadas describen el evento y su ubicación; **nst**, **gap**, **dmin** y **rms** caracterizan cobertura y ajuste técnico; **magType** y **net** controlan diferencias promedio de codificación. Las correlaciones y distribuciones se utilizan como diagnóstico complementario para detectar escalas, asimetrías y colinealidad, no como regla automática de selección.

Tabla 2
Grupos conceptuales de los predictores

Grupo Conceptual	Variables incluidas y justificación
Geofísicas y espaciales	depth , depth ² , latitude , longitude . El log de profundidad se conserva como sensibilidad.
Técnicas del registro	$\log(\text{nst} + 1)$, $\log(\text{gap} + 1)$, $\log(\text{dmin} + 1)$ y rms . Resumen cobertura, geometría, proximidad y ajuste.
Codificación del catálogo	magType_grouped , net_grouped . Permiten estimar diferencias promedio por método de magnitud y red reportante.

Respecto a las consideraciones éticas del estudio: Los datos no contienen información personal y el riesgo ético directo es bajo. Aun así, el uso responsable exige evitar conclusiones de seguridad pública, alertas o lenguaje de predicción operacional. Las variables técnicas pueden asociarse con la magnitud reportada, pero no se interpretan como causas físicas directas.

3. Limpieza y Codificación inicial

La base de datos inicial contiene 14.176 registros. Con el fin de adecuar las variables disponibles para el análisis estadístico y asegurar la consistencia de los posteriores modelos, se llevó a cabo un proceso de conversión de variables, estructuración, agrupación y gestión de datos faltantes, el cual se describe a continuación:

3.1. Procesamiento y codificación

- **Normalización de fechas:** La variable `time` se convirtió formalmente al estándar de fecha-hora UTC. Luego, se derivaron el resto de componentes temporales, esto es, `month` (mes), `hour` (hora del evento) y `weekday` (día de la semana).
- **Conversión de tipos:** Las variables continuas se convirtieron a formato numérico con `errors="coerce"`; los valores no interpretables quedan registrados como faltantes para su revisión.
- **Transformaciones candidatas:** Se creó `log_depth_plus_1` mediante `log1p(depth.clip(lower=0))`, pero no se adoptó automáticamente. La asimetría de un predictor no viola MCO; la decisión final compara profundidad lineal, cuadrática y logarítmica sobre la misma muestra. También se evaluaron escalas originales y $\log(x + 1)$ para `nst`, `gap`, `dmin` y `rms`. Todas las transformaciones se justifican en la Sección 5.3 mediante ajuste, validación, dominio e interpretación.
- **Extracción textual:** Desde `place` se obtuvo `region_from_place`, tomando el texto posterior a la última coma; los textos sin coma se codificaron como *Unknown/No comma*.
- **Agrupación de categorías:** Se exigieron al menos 30 eventos por nivel. En `magType` se conservaron `mb`, `md`, `ml`, `mw`, `mwr` y `mwu`; `mwb` y `mh` se agruparon como *Other* (5 eventos). En `net` se conservaron `us`, `ak`, `pr`, `nc` y `ci`; las seis redes restantes se agruparon como *Other* (38 eventos). `region_grouped`, usada solo descriptivamente, retuvo las 45 regiones más frecuentes y agrupó 607 eventos como *Other*.

3.2. Control de calidad de los datos

Se ejecutó una revisión en la consistencia interna de la base de datos para el análisis de identificadores únicos (validación y descarte de registros duplicados a través de la variable) y verificación de los límites físicos esperados para las magnitudes, coordenadas geográficas y profundidades.

Tabla 3

Resultados de la revisión y rangos observados de los datos

Revisión	Resultado
Duplicados por id	0 registros involucrados (0 ids duplicados).
Rango observado de mag	4.0 a 7.5
Rango observado de depth	-0.070 a 671.043
Rango observado de latitude	-65.301 a 86.605
Rango observado de longitude	-179.999 a 179.998
Profundidades negativas	1 evento; se reporta y no se elimina automáticamente.
Faltantes principales	<code>dmin</code> : 52 (0.37 %); <code>gap</code> : 52 (0.37 %); <code>nst</code> : 51 (0.36 %); <code>rms</code> : 1 (0.01 %)

Luego, la inspección confirma que no hay duplicados por `id`. Los faltantes principales se concentran en `dmin`, `gap`, `nst` y `rms`, mientras que `mag`, `depth`, `latitude` y `longitude` no presentan faltantes en la base procesada.

3.3. Tratamiento de datos faltantes

No se eliminan automáticamente valores atípicos de magnitud o profundidad. Para la modelación se utiliza análisis de casos completos: una observación se excluye solo si carece de alguna variable requerida por la especificación comparada [11]. La decisión se considera razonable como aproximación inicial porque la pérdida máxima es 52 de 14.176 eventos (0.37 %); sin embargo, puede introducir sesgo si la ausencia no es aproximadamente aleatoria, por lo que se revisarán patrones de faltantes y sensibilidad. Para comparar AIC, BIC y pruebas F, todos los modelos M1–M6 se ajustan sobre la misma muestra de 14.124 casos completos. Esta estrategia se apoya en los siguientes criterios:

- **Baja incidencia:** La pérdida de información es mínima; la variable con mayor proporción de datos faltantes (`dmin`) representa apenas el 0.37 % del total de la muestra.
- **Comparabilidad:** Los modelos candidatos se estiman sobre idénticas observaciones, evitando atribuir a un bloque de regresores cambios producidos solo por variaciones de muestra.
- **Transparencia:** No se imputan valores sin un modelo explícito de ausencia; la limitación del análisis de casos completos queda declarada.

Después de la limpieza inicial se mantienen 14.176 eventos en la base procesada. La muestra común usada para comparar los modelos contiene 14.124 eventos.

Tabla 4
Resumen del conjunto de datos y consideraciones metodológicas

Campo	Descripción
Fuente	U.S. Geological Survey, Earthquake Catalog API.
Contexto	Eventos sísmicos registrados durante 2024 con magnitud al menos 4.
Unidad de observación	Evento sísmico registrado en el catálogo.
Variable dependiente numérica	Magnitud del evento (<code>mag</code>).
Predictores candidatos	<code>depth</code> , <code>latitude</code> , <code>longitude</code> , <code>nst</code> , <code>gap</code> , <code>dmin</code> , <code>rms</code> , <code>magType</code> , <code>net</code> , <code>month</code> , <code>hour</code> y <code>region_from_place</code> .
Tamaño muestral	14,176 eventos después de la limpieza inicial.
Datos faltantes	<code>dmin</code> (0.37 %); <code>gap</code> (0.37 %); <code>nst</code> (0.36 %); <code>rms</code> (0.01 %)
Dificultades del análisis	Truncamiento por $\text{mag} \geq 4$; asimetría o concentración de magnitudes; valores atípicos; faltantes en variables técnicas; posible colinealidad; dependencia espacial; categóricas con muchas categorías; variables técnicas no necesariamente causales.

4. Análisis exploratorio de datos (EDA)

Una vez consolidada la base, el análisis exploratorio caracteriza distribuciones e identifica patrones preliminares de asociación lineal, categórica y espacial. La Tabla 5 resume tendencia central, dispersión y rangos de las variables numéricas utilizadas.


Tabla 5*Estadísticas descriptivas de las variables numéricas analizadas*

Variable	n	Media	Mediana	Desv. Est.	Mínimo	Máximo
mag	14176	4.491	4.400	0.376	4.000	7.500
depth	14176	92.463	34.622	142.314	-0.070	671.043
log_depth_plus_1	14176	3.643	3.573	1.305	0.000	6.510
latitude	14176	3.451	0.969	28.565	-65.301	86.605
longitude	14176	33.277	91.571	122.858	-179.999	179.998
nst	14125	49.793	35.000	42.680	7.000	619.000
gap	14124	106.742	102.000	45.778	10.000	343.000
dmin	14124	3.654	2.284	4.844	0.000	62.558
rms	14175	0.707	0.690	0.221	0.000	1.740


A partir del resumen estadístico de las variables, se destacan los siguientes comportamientos en la muestra inicial ($n = 14.176$):

- **Magnitud (mag):** Varía entre 4.0 y 7.5, con media 4.491 y mediana 4.400. El 75 % de los eventos no supera 4.6; esta concentración está condicionada por el filtro de inclusión y debe considerarse al interpretar los modelos.
- **Profundidad (depth):** Presenta media 92.463 km, mediana 34.622 km y desviación estándar 142.314 km. La diferencia entre media y mediana evidencia asimetría a la derecha, con eventos profundos informativos que se conservan en el análisis.
- **Variables técnicas:** **nst** tiene media 49.793 y máximo 619, mientras **gap** promedia 106.742 grados y alcanza 343. Estas escalas heterogéneas motivan revisar influencia, forma funcional y varianza residual, sin convertirlas en explicaciones causales.


Para complementar el análisis brindado por los estadísticos de tendencia central, se evaluó además la distribución de los predictores, los principales hallazgos se presentan en la Figura 1 y Figura 2.




(a) *Distribución de mag.*



(b) *mag y log profundidad.*



(c) *Ubicación coloreada por magnitud.*



(d) *Magnitud por magType.*

Figura 1

EDA principal ligado a la pregunta: distribución de la respuesta, asociación con profundidad transformada, patrón espacial y diferencias promedio por tipo de magnitud.

El mapa de la Figura 1.c muestra una distribución espacial concentrada en franjas y regiones sísmicamente activas, coherente de manera general con zonas del Cinturón de Fuego del Pacífico [4]. El gráfico no prueba dependencia ni causalidad espacial, pero justifica incorporar latitud y longitud como controles y revisar si los residuos conservan estructura geográfica.

El boxplot por tipo de magnitud (Figura 1.d) exhibe diferencias en nivel y dispersión entre métodos. Estas diferencias pueden reflejar ámbitos de aplicación y reglas de codificación distintas; por ello se incluyen indicadores de `magType_grouped`. Se trata de diferencias descriptivas dentro del catálogo, no de evidencia de sesgo causal ni de superioridad de un método.




Figura 2

Distribuciones de covariables principales: profundidad transformada, coordenadas y número de estaciones. Cada panel explicita el significado y la unidad o escala utilizada.




Figura 2

Distribuciones de covariables principales (continuación): brecha azimutal, distancia mínima transformada y error RMS. El recorte p1-p99 se usa solo para visualizar gap y rms; ninguna observación se elimina por este gráfico.




Figura 2

Distribuciones de covariables principales (continuación): método usado para reportar la magnitud y red que aportó la solución. La escala logarítmica del conteo permite visualizar niveles frecuentes y poco frecuentes sin alterar los datos.

El análisis exploratorio de los datos está directamente conectado con la pregunta de investigación. La magnitud aparece concentrada cerca del umbral 4 por el filtro de inclusión (Figura 1.a), por lo que las asociaciones se interpretan dentro de eventos moderados o mayores. El mapa muestra concentración espacial de eventos, lo que justifica incluir latitud y longitud como controles; además, las diferencias promedio por **magType** respaldan incorporar indicadores de tipo de magnitud. Estas relaciones son descriptivas y no se leen como efectos causales.

Las distribuciones de predictores complementan esta lectura (Figura 2): **log_depth_plus_1**, **nst**, **gap**, **dmin** y **rms** muestran escalas y asimetrías distintas, lo que respalda revisar transformaciones y diagnósticos; las barras de **magType_grouped** y **net_grouped** muestran por qué conviene agrupar niveles poco frecuentes antes de usar indicadores.

5. Modelación e inferencia

5.1. Plan de modelos

Para la modelación de la regresión múltiple se considera una secuencia de modelos lineales anidados interpretables. M1 evalúa la asociación marginal con profundidad transformada; M2 agrega ubicación básica mediante latitud y longitud; M3 incorpora variables técnicas del registro; M4 agrega diferencias promedio por tipo de magnitud; M5 revisa si la red de reporte captura diferencias adicionales; y M6 permite una relación espacial flexible con términos cuadráticos e interacción latitud-longitud, sin salir del marco de regresión lineal. Estas comparaciones evalúan qué bloque de variables aporta evidencia preliminar, controlando por las demás variables incluidas.

Tabla 6

Bloques de modelos lineales candidatos y propósito estadístico

Modelo	Bloque agregado	Propósito estadístico
M1	log_depth_plus_1	Evaluar la asociación marginal entre profundidad y magnitud.
M2	M1 + latitude + longitude	Controlar por localización espacial lineal.
M3	M2 + nst + gap + dmin + rms	Agregar cobertura y ajuste técnico del registro.
M4	M3 + magType_grouped	Estimar diferencias promedio según el método de magnitud reportado.
M5	M4 + net_grouped	Evaluar diferencias adicionales asociadas con la red reportante.
M6	M4 + latitude ² + longitude ² + (latitude × longitude)	Permitir una asociación espacial no estrictamente lineal (curvatura e interacción).

Tabla 7

Comparación de rendimiento y criterios de información de los modelos estimados

Modelo	n	Parámetros	R ² ajust.	AIC	BIC	RMSE	MAE
M1	14176	2	0.028	12096.022	12111.141	0.371	0.268
M2	14176	4	0.048	11801.695	11831.933	0.367	0.264
M3	14124	8	0.535	1633.633	1694.079	0.256	0.184
M4	14124	15	0.624	-1361.202	-1247.868	0.230	0.170
M5	14124	22	0.625	-1390.252	-1224.028	0.230	0.170
M6	14124	18	0.633	-1688.352	-1552.351	0.228	0.168

Respecto al análisis del rendimiento de los modelos en la Tabla 7 se puede evidenciar una evolución crucial en la capacidad predictiva. Los modelos puramente geofísicos iniciales (**M1** y **M2**) muestran un ajuste sumamente pobre, con un R^2 ajustado inferior al 5 %. Sin embargo, al anidar el modelo **M3** se reduce el AIC de manera drástica (de 11801.695 a 1633.633) y el R^2 ajustado aumenta hasta 0.535, presentando una clara evidencia que no bastan las características físicas del evento para un buen rendimiento; la calidad y la geometría que la red de captura (variables instrumentales) son determinantes en la variabilidad de la magnitud reportada.

Luego, el rendimiento se comienza a consolidar en los bloques superiores. Al introducir los controles metodológicos del tipo de magnitud (**M4**), los criterios de información logran valores negativos, indicando un ajuste superior. Al analizar la incorporación de las redes de reporte en el **M5**, podemos apreciar un leve sobreajuste, ya que a pesar de aumentar a 22 parámetros, el (BIC) empeora de -1247.868 a -1224.028 , lo que nos sugiere que la incorporación de las distintas agencias que evalúan el sismo no añade un valor

predictivo real. Finalmente, el modelo que permite modelar la curvatura espacial **M6** resulta el más eficiente del catálogo, alcanzando el menor AIC (-1688.352) y el menor BIC (-1552.351) y con una reducción de 4 parámetros respecto al anterior.

La comparación preliminar sugiere mejoras importantes al pasar de modelos puramente geográficos a modelos con variables técnicas y tipo de magnitud. Sin embargo, el modelo final no se escogerá solo por R2 o AIC/BIC: se priorizará interpretabilidad, diagnóstico de supuestos, colinealidad, observaciones influyentes y estabilidad ante categorías agrupadas. Dentro de esta etapa, **M4** (como modelo lineal parsimonioso e interpretable) y el **M6** (como modelo más robusto) se establecen como los candidatos naturales para la fases siguientes de diagnósticos.

5.2. Modelo general y supuestos

Se trabaja con $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$. El modelo es lineal en $\boldsymbol{\beta}$ aunque incluya cuadrados e interacciones. MCO proyecta $\mathbf{Y}$ ortogonalmente sobre $C(\mathbf{X})$ mediante $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$; el modelo con solo intercepto corresponde a $\mathbf{H}_0 = \mathbf{J}_n/n$ y permite la descomposición $SCT = SCR + SCE$ [6]. El modelo nulo se usa como referencia geométrica, no como candidato sustantivo.

Los supuestos evaluados son: A1, especificación de la media y linealidad en parámetros; A2, rango completo de $\mathbf{X}$; A3, $E(\boldsymbol{\varepsilon} | \mathbf{X}) = 0$; A4, varianza constante y ausencia de correlación; y A5, normalidad para inferencia exacta. Los diagnósticos no prueban que el modelo sea verdadero: permiten detectar incompatibilidades y escoger remedios.

5.3. Decisiones de transformación

5.3.1. Profundidad

La asimetría de **depth** no obliga a transformarla, pues MCO no requiere predictores normales. Se comparan especificaciones con igual respuesta y muestra. Dentro de cada escala, agregar el cuadrado es una comparación anidada; entre **depth** y $\log(\text{depth}+1)$ los modelos no son anidados, por lo que no corresponde una prueba F entre escalas.

Tabla 8
Comparación de escalas y formas funcionales para profundidad

Especificación	Parámetros	R2 ajustado	AIC	BIC	RMSE	CV RMSE
depth lineal	22	0.666	-3026.340	-2860.117	0.217	0.218
depth + depth ²	23	0.671	-3248.864	-3075.085	0.215	0.216
log1p(depth.clip(0)) lineal	22	0.665	-2966.144	-2799.920	0.217	0.218
log1p(depth.clip(0)) + cuadrado	23	0.671	-3230.032	-3056.252	0.215	0.216
log1p(depth) + cuadrado	23	0.671	-3230.001	-3056.222	0.215	0.216

El cuadrado de profundidad aporta sobre la forma lineal ($F = 225.95$, $p < 0.001$). La especificación **depth+depth²** alcanza AIC -3248.86 y CV-RMSE 0.2161, mejores que el log lineal y ligeramente mejores que el log cuadrático. Por ello se usa profundidad original estandarizada con término cuadrático. La pendiente local cambia con profundidad y con longitud; no se interpreta como efecto causal.

Solo un evento tiene profundidad negativa (-0.07 km). Como es mayor que -1 , $\log(\text{depth}+1)$ sin recorte está definido. Las versiones con y sin recorte entregan AIC y CV-RMSE prácticamente iguales, de modo

que esa observación no determina la decisión. Los eventos profundos se conservan.

5.3.2. Variables técnicas

Para **nst**, **gap**, **dmin** y **rms** se contrastaron escala original y $\log(x + 1)$. El dominio se cumple porque son no negativas; $\log 1p$ también admite ceros. La motivación es representar cambios marginales decrecientes, no normalizar los predictores.

Tabla 9

Sensibilidad a transformaciones de predictores técnicos

Especificación	R2 ajustado	AIC	BIC	RMSE	CV RMSE
Final: log nst, log gap, log dmin, rms	0.671	-3248.864	-3075.085	0.215	0.216
nst original	0.645	-2144.631	-1970.851	0.224	0.225
gap original	0.671	-3213.651	-3039.872	0.216	0.216
dmin original	0.671	-3237.668	-3063.888	0.215	0.216
log rms	0.671	-3249.631	-3075.852	0.215	0.216

$\log(\mathbf{nst} + 1)$ produce una mejora amplia; $\log(\mathbf{dmin} + 1)$ una mejora moderada; y $\log(\mathbf{gap} + 1)$ una mejora pequeña pero consistente en AIC, BIC y validación. Esta última expresa que un aumento relativo de la brecha puede importar más cuando la cobertura inicial es buena que cuando ya es deficiente. $\log(\mathbf{rms} + 1)$ cambia el ajuste de forma despreciable, por lo que **rms** se mantiene en segundos. Estandarizar después de transformar no cambia el ajuste: centra el intercepto, iguala unidades y reduce colinealidad no esencial.

5.3.3. Respuesta y Box–Cox

Box–Cox exige $Y > 0$, condición satisfecha porque **mag** ≥ 4 . El perfil se calculó dentro del modelo completo e incluyó el jacobiano $(\lambda - 1) \sum_i \log y_i$ [7]; por ello sí permite comparar λ , a diferencia de comparar R^2 de respuestas distintas. El máximo es $\hat{\lambda} = -2.475$ con IC 95 % $[-2.625, -2.350]$.

Tabla 10

Diagnósticos residuales bajo transformaciones de la respuesta

Transformación	lambda	BP p-valor	RESET p-valor	JB p-valor
Identidad	1.000	<0.001	<0.001	<0.001
Raíz	0.500	<0.001	0.006	<0.001
Log	0.000	<0.001	0.346	<0.001
Perfil	-2.475	<0.001	<0.001	<0.001

No se adopta Box–Cox. La muestra está truncada en 4 y la acumulación en el umbral influye en el perfil; **mag** ya representa una escala logarítmica sismológica; la retransformación exigiría corrección de sesgo; y heterocedasticidad y no normalidad continúan bajo todas las alternativas. El log de **mag** reduce evidencia RESET, pero sería el logaritmo de una escala ya logarítmica y no resuelve BP ni JB. Los R^2 transformados no se comparan con el de la respuesta original.

5.4. Secuencia y modelo final

M4 es la línea base. G1 transforma y estandariza predictores; G2 agrega curvatura; G3 incorpora todas las interacciones candidatas; y G final elimina $\log(\text{nst} + 1)^2$, rms^2 , $\log(\text{gap} + 1) \times \log(\text{dmin} + 1)$ y $\text{depth} \times \text{latitude}$. Se conserva jerarquía: cada variable de un cuadrado o interacción aparece como efecto principal.

Tabla 11

Comparación de especificaciones sobre los mismos 14.124 eventos

Modelo	n	Parámetros	R2 ajustado	AIC	BIC	RMSE	MAE
M4 base	14124	14	0.624	-1343.832	-1238.053	0.231	0.171
G1 escalas	14124	14	0.645	-2182.050	-2076.271	0.224	0.166
G2 curvatura	14124	22	0.668	-3086.873	-2920.649	0.217	0.159
G3 completo	14124	27	0.671	-3244.356	-3040.354	0.215	0.158
G final	14124	23	0.671	-3248.864	-3075.085	0.215	0.158

G final contiene 23 parámetros, R^2 ajustado 0.6715, RMSE 0.2153 y los menores AIC/BIC de la secuencia. La reducción desde G3 no es rechazada ni por F clásica ($p = 0.480$) ni por el contraste HC3 ($p = 0.612$), mientras curvatura e interacciones sí aportan ($p < 0.001$).

Tabla 12

Pruebas de bloques anidados: referencia clásica y contraste HC3

Comparación	gl	F clásico	p clásico	F HC3	p HC3
G1 vs G2: curvatura	8	118.753	<0.001	114.755	<0.001
G2 vs G3: interacciones	5	33.632	<0.001	16.705	<0.001
G final vs G3: términos retirados	4	0.871	0.480	0.671	0.612

Con variables estandarizadas z y mb como referencia, la especificación exacta es

$$\begin{aligned}
\text{mag}_i = & \beta_0 + \beta_1 z_{d,i} + \beta_2 z_{lat,i} + \beta_3 z_{lon,i} + \beta_4 z_{nst,i} + \beta_5 z_{gap,i} + \beta_6 z_{dmin,i} + \beta_7 z_{rms,i} \\
& + \sum_{k \neq mb} \gamma_k D_{ik} + \beta_8 z_{d,i}^2 + \beta_9 z_{lat,i}^2 + \beta_{10} z_{lon,i}^2 + \beta_{11} z_{gap,i}^2 + \beta_{12} z_{dmin,i}^2 \\
& + \beta_{13} z_{lat,i} z_{lon,i} + \beta_{14} z_{nst,i} z_{gap,i} + \beta_{15} z_{nst,i} z_{dmin,i} + \beta_{16} z_{d,i} z_{lon,i} + \varepsilon_i.
\end{aligned}$$

Aquí z_{nst} , z_{gap} y z_{dmin} estandarizan las respectivas transformaciones $\log(x + 1)$, mientras z_d estandariza depth original. Para magType se usan seis indicadores D_{ik} y se omite mb ; esta codificación $k - 1$ evita la trampa de variables dummy y hace del intercepto la media ajustada del grupo de referencia. La jerarquía se preserva: todo predictor involucrado en un cuadrado o interacción aparece también como efecto principal.

5.5. ANOVA, contrastes e interpretación

La ANOVA clásica contrasta que las 22 pendientes sean cero y descompone la variabilidad, pero su inferencia exacta requiere homocedasticidad y normalidad. Como ambos supuestos se rechazan, los contrastes

HC3 constituyen la inferencia principal [8].

Tabla 13

ANOVA clásica del modelo final

Fuente	SC	gl	CM	F	p-valor
Regresión	1341.502	22	60.977	1312.949	<0.001
Error	654.893	14101	0.046		
Total	1996.395	14123			

Tabla 14

Contrastes F robustos HC3 por bloque del modelo final

Bloque	gl	F robusto	p-valor
Profundidad	3	819.621	<0.001
Curvatura espacial	3	133.483	<0.001
Curvatura técnica	2	7.639	<0.001
Interacciones técnicas	2	46.595	<0.001
Tipo de magnitud	6	292.528	<0.001

Profundidad, curvatura espacial, curvatura técnica, interacciones técnicas y tipo de magnitud aportan conjuntamente ($p < 0.001$). Los coeficientes implicados en cuadrados o interacciones son pendientes locales cuando las otras variables estandarizadas valen cero; no deben leerse como efectos constantes.

Tabla 15

Coefficientes continuos e inferencia de sensibilidad

Término	Estimación	EE HC3	p HC3	EE clúster región	p clúster región
Intercepto (mb, perfil centrado)	4.3757	0.0047	<0.001	0.0152	<0.001
profundidad (1 DE)	-0.1597	0.0043	<0.001	0.0095	<0.001
latitud (1 DE)	-0.0966	0.0025	<0.001	0.0047	<0.001
longitud (1 DE)	0.0418	0.0028	<0.001	0.0092	<0.001
log nst (1 DE)	0.1894	0.0028	<0.001	0.0064	<0.001
log gap (1 DE)	-0.0370	0.0026	<0.001	0.0071	<0.001
log dmin (1 DE)	0.0269	0.0025	<0.001	0.0079	0.001
rms (1 DE)	0.0115	0.0018	<0.001	0.0029	<0.001
profundidad al cuadrado	0.0271	0.0019	<0.001	0.0031	<0.001
log gap al cuadrado	-0.0108	0.0031	<0.001	0.0053	0.049
log dmin al cuadrado	0.0026	0.0014	0.054	0.0025	0.301
log nst $\times$ log gap	-0.0360	0.0038	<0.001	0.0067	<0.001
log nst $\times$ log dmin	0.0054	0.0027	0.041	0.0038	0.155
profundidad $\times$ longitud	0.0036	0.0017	0.035	0.0032	0.270

El intercepto 4.376 corresponde a un evento *mb* con profundidad 92.64 km, latitud 3.24, longitud 33.96, **nst** 38.47, **gap** 96.51, **dmin** 2.52 y **rms** 0.707. Todos esos valores están dentro de sus rangos observados y *mb* es la categoría mayoritaria. El vector exacto no necesita ser un evento real: es un perfil de referencia; el evento **us6000m416** está a 0.69 unidades de distancia estandarizada y muestra que la referencia no está aislada del soporte.

Para las seis diferencias de **magType** frente a *mb* se usan intervalos simultáneos Bonferroni, adecuados al

conjunto finito preespecificado y menos conservadores que Scheffé. Solo mwu (+0.431) y mwr (−0.189) excluyen cero simultáneamente; los demás, sobre todo *Other* (cinco casos), tienen mayor incertidumbre.

6. Diagnóstico y remedios

Tabla 16

Estado de los supuestos y respuesta metodológica

Supuesto	Evidencia	Conclusión y acción
A1: media bien especificada	Lineal en beta; RESET rechaza	Cumplimiento parcial; cuadrados/interacciones y validación
A2: rango completo	$\text{rank}(X)=23=p$	Identificable; revisar VIF y condición
A3: $E(\text{error} X)=0$	No comprobable con datos observacionales	No interpretar causalmente; reconocer omisión/error de medición
A4: varianza/dependencia	BP y White rechazan; DW/ACF y Ljung-Box sugieren dependencia	HC3 principal; clúster por región y validación espacial
A5: normalidad	JB y Shapiro-Wilk rechazan	Inferencia exacta clásica no se sostiene; gran n y robustez

6.1. Geometría y colinealidad

X tiene rango completo (23/23), $\sum h_{ii} = 23$, $X^\top e \approx 0$ y la proyección es numéricamente idempotente. El número de condición bruto es 179.49 por escalas y frecuencias de indicadores; al normalizar columnas disminuye a 7.73. El VIF máximo es 6.65 para profundidad² y 6.00 para profundidad. Es colinealidad moderada y esperable en un polinomio, no no-identificabilidad; por ello profundidad se interpreta como bloque y no se elimina un término jerárquico solo para reducir VIF.

6.2. Forma funcional, heterocedasticidad y normalidad

Tabla 17

Pruebas formales de diagnóstico del modelo final

Prueba	H0	Estadístico	p-valor
F global	Todas las pendientes son cero	1312.949	<0.001
Breusch-Pagan	Varianza constante (forma lineal)	1566.812	<0.001
White	Varianza constante (forma general)	3024.538	<0.001
Jarque-Bera	Normalidad residual	32276.230	<0.001
Shapiro-Wilk (n=5000)	Normalidad residual	0.947	<0.001
Ramsey RESET	Forma funcional adecuada	22.656	<0.001
Durbin-Watson	Sin autocorrelación de primer orden	1.731	—
Ljung-Box (10 rezagos)	Autocorrelaciones 1–10 iguales a cero	679.556	<0.001

Breusch–Pagan rechaza varianza constante bajo una forma lineal para la varianza; White también rechaza bajo una alternativa más general [8]. MCO puede seguir estimando la media bajo A3, pero los errores estándar clásicos quedan mal calibrados. Se usa HC3 como principal y errores agrupados por `region_grouped`

como sensibilidad a dependencia intrarregional. Los efectos principales permanecen, mientras términos pequeños pierden precisión agrupada; esa inestabilidad se declara.




Figura 3
Diagnóstico de media y varianza del modelo final.

RESET aún rechaza, de modo que el modelo es una aproximación útil y no la forma verdadera del proceso. Jarque-Bera y Shapiro-Wilk rechazan normalidad; con $n = 14.124$ detectan desviaciones pequeñas, pero el QQ-plot confirma colas pesadas. La normalidad no es necesaria para calcular MCO, aunque sí para inferencia t/F exacta en muestras finitas.




Figura 4
Normalidad y dependencia secuencial de los residuos.

Durbin-Watson es 1.731, la ACF muestra correlación positiva inicial y Ljung-Box a diez rezagos rechaza ausencia conjunta de autocorrelación ($p < 0.001$) [10]. Son tamizajes, no evidencia concluyente de un

proceso AR(1), porque los eventos no están igualmente espaciados y el orden temporal mezcla regiones. Un CAR tampoco es directo para puntos sin agregación territorial. La sensibilidad por región y la validación espacial cuantifican parte de esta fragilidad.

6.3. Influencia y robustez

Se revisan residuos estudentizados internos y externos, leverage, Cook, DFFITS, DFBETAS y COVRATIO. Las reglas $h_{ii} > 2p/n$, $D_i > 4/n$ y $|t_i| > 3$ señalan 907, 739 y 147 eventos. Son reglas de inspección, no criterios de eliminación: sismos grandes y profundos son observaciones reales e informativas. `hv74260121` combina leverage 0.202 y Cook 0.203; `nc75095651`, magnitud 7.0, tiene residuo externo 12.52. Ambos se conservan.

La M-estimación de Huber [9] produce cambios absolutos inferiores a 0.004 en los efectos principales estandarizados, por lo que su signo y orden de magnitud no dependen de pocos residuos grandes. MCO+HC3 sigue siendo principal porque la pregunta se refiere a la media condicional y requiere inferencia transparente.

WLS con varianza estimada deja RMSE 0.2156 y Breusch–Pagan aún rechaza; no se adopta. Ridge/Lasso tampoco son remedios necesarios: no hay deficiencia de rango y penalizar sesgaría coeficientes centrales. IV/2SLS no se usa porque no existe un instrumento cuya relevancia y exogeneidad sean defendibles. A3 permanece como limitación por omisión, simultaneidad y error de medición.

7. Selección, validación e incertidumbre

La selección combina bloques sustantivos, F parcial, Wald HC3, AIC/BIC, jerarquía y parsimonia. Se evalúa con CV aleatoria, CV agrupada por región y corte temporal 80/20. En cada partición las transformaciones y estandarizaciones se estiman solo en entrenamiento, evitando filtración.

Tabla 18
Validación fuera de muestra de M4 y del modelo final

Esquema	Modelo	RMSE	MAE	R2	SD_RMSE	SD_R2
CV aleatoria 5-fold	G final	0.216	0.159	0.669	0.004	0.002
CV aleatoria 5-fold	M4 base	0.231	0.171	0.622	0.005	0.011
CV por región 5-fold	G final	0.225	0.165	0.633	0.024	0.064
CV por región 5-fold	M4 base	0.236	0.174	0.597	0.022	0.066
Corte temporal 80/20	G final	0.226	0.163	0.638	0.000	0.000
Corte temporal 80/20	M4 base	0.237	0.174	0.602	0.000	0.000

G final mejora a M4 en los tres esquemas: CV aleatoria RMSE 0.216 y $R^2 = 0.669$; CV regional RMSE 0.225 y $R^2 = 0.633$; corte temporal RMSE 0.226 y $R^2 = 0.639$. La caída al separar regiones o tiempo evidencia heterogeneidad no capturada.

La selección e inferencia usan la misma muestra, de modo que algunos p-valores posteriores a explorar especificaciones pueden ser optimistas. Se mitiga con bloques predefinidos, contrastes robustos, Bonferroni y validación, pero no se elimina sin una muestra externa. Un intervalo de predicción individual sería

más ancho que uno para la media y, bajo heterocedasticidad, no debe construirse suponiendo varianza constante. Además, las variables técnicas se conocen después del registro: el análisis no anticipa dónde ni cuándo ocurrirá un sismo.

8. Interpretación, limitaciones y acción propuesta

Dentro del catálogo USGS 2024 truncado en magnitud 4, la magnitud reportada se asocia con profundidad, ubicación, cobertura técnica y tipo de magnitud. La evidencia favorece profundidad cuadrática en escala original; logaritmos para **nst**, **gap** y **dmin**; curvatura espacial y técnica; e interacciones seleccionadas. Estas decisiones mejoran ajuste y validación respecto de M4, pero no eliminan heterocedasticidad, colas pesadas ni dependencia residual.

Las relaciones no identifican causas físicas. La recomendación es usar el modelo para comparaciones ajustadas y revisiones descriptivas del catálogo por región y método de magnitud. No debe utilizarse para alertas, predicción operacional ni decisiones de seguridad pública. Una extensión futura necesitaría datos y supuestos explícitos para dependencia espacial-temporal y error de medición.

9. Reproducibilidad

El notebook `avance_proyecto_corregido.ipynb` genera la base procesada `usgs_earthquakes_2024_mag4_model_ready.csv`, las tablas en `Plantilla_informe/tables/` y las figuras en `Plantilla_informe/figures/`, siempre mediante rutas relativas a `Final/`. El repositorio está disponible en https://github.com/Paul0112/proyecto_regresion; las versiones se documentan en `requirements.txt` y `session_info.txt`.

Declaración de uso de herramientas de IA

Se utilizaron herramientas de inteligencia artificial para apoyar la mejora de gráficos en Python, la fluidez de redacción y el orden y disposición de tablas e imágenes en LaTeX. Las decisiones metodológicas, la ejecución y la interpretación de resultados fueron revisadas por los autores.

Resumen técnico

Sobre 14.124 eventos con información completa, la especificación final conserva **mag** en su escala original y utiliza profundidad estandarizada con término cuadrático, controles espaciales, transformaciones $\log(x+1)$ para **nst**, **gap** y **dmin**, **rms** sin transformar e indicadores de **magType**. Esta forma mejora el ajuste y la validación respecto de M4 (R^2 ajustado 0.6715; CV-RMSE 0.216), pero no elimina heterocedasticidad, colas residuales pesadas ni dependencia geográfica o temporal.

Por ello, la inferencia principal emplea errores estándar HC3 y se contrasta con agrupación por región. Las conclusiones describen asociaciones promedio dentro del catálogo USGS 2024 truncado en magnitud 4; no establecen causalidad ni permiten anticipar sismos.

Referencias

- [1] U.S. Geological Survey, *Earthquake Catalog API*,
<https://earthquake.usgs.gov/fdsnws/event/1/>
- [2] Python Software Foundation, *Python Language Reference*,
<https://www.python.org/>
- [3] Organización Panamericana de la Salud (OPS). (s.f.). *Terremotos*. Organización Mundial de la Salud. Recuperado el 10 de junio de 2026, de <https://www.paho.org/es/temas/terremotos>
- [4] CNN en Español. (2024, 2 de abril). *¿Qué es el Cinturón de Fuego del Pacífico y por qué es tan peligroso?* Recuperado de: <https://cnnespanol.cnn.com/2024/04/02/cinturon-fuego-pacifico-explainer-orix>
- [5] Minson, S. E., Meier, M.-A., Baltay, A. S., Hanks, T. C., & Cochran, E. S., *The Limits of Earthquake Early Warning Accuracy and Best Alerting Strategy*, Scientific Reports, Vol. 9, Article 2478 (2019),
<https://doi.org/10.1038/s41598-019-39384-y>
- [6] Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to Linear Regression Analysis* (6th ed.). Wiley.
- [7] Box, G. E. P., & Cox, D. R. (1964). An analysis of transformations. *Journal of the Royal Statistical Society: Series B*, 26(2), 211–252.
- [8] White, H. (1980). A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4), 817–838.
- [9] Huber, P. J. (1964). Robust estimation of a location parameter. *The Annals of Mathematical Statistics*, 35(1), 73–101.
- [10] Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- [11] Little, R. J. A., & Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3rd ed.). Wiley.