



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE MATEMÁTICAS
DEPARTAMENTO DE ESTADÍSTICA
PROFESOR: ELOY ALVARADO NARVÁEZ
CURSO: ANÁLISIS DE REGRESIÓN (EYP2307)
PRIMER SEMESTRE 2026

Proyecto aplicado

Aplicación de regresión lineal múltiple a datos reales. El proyecto considera un avance, un informe final y una presentación oral.

Objetivo general

El objetivo del proyecto es aplicar los contenidos de la asignatura a un conjunto de datos real, contextualizado y proveniente de una fuente confiable. Cada grupo deberá formular una pregunta descriptiva o predictiva, ajustar modelos de regresión lineal, diagnosticar sus supuestos, interpretar los resultados y proponer una acción, recomendación o lectura aplicada basada en la evidencia encontrada.

El trabajo debe mostrar dominio de las herramientas vistas hasta la semana 9b: mínimos cuadrados ordinarios, inferencia sobre parámetros, pruebas t y F , ANOVA de regresión, intervalos de confianza y predicción, análisis de residuos, selección de variables, colinealidad, heterocedasticidad, autocorrelación y observaciones influyentes. Los contenidos que resten por ver al momento del avance también forman parte del curso. Si el conjunto de datos o la pregunta los amerita, se espera que sean incorporados en el informe final con una justificación clara; no basta con omitir una herramienta pertinente sólo porque aún no era necesaria en el avance.

Organización de grupos

El curso se organizará en 10 grupos: 8 grupos de 4 estudiantes y 2 grupos de 3 estudiantes. La inscripción de grupos se realizará mediante el módulo de CANVAS ya disponible. Cada estudiante debe quedar inscrito en un grupo antes de iniciar el avance.

Cada grupo trabajará con un conjunto de datos distinto, elegido desde la lista de la sección “[Conjuntos de datos disponibles](#)”, o bien con datos propios aprobados según la sección “[Propuesta de conjuntos de datos propios](#)”. La selección de datos se hará por preferencias en clase. Si dos o más grupos solicitan el mismo conjunto de datos, la asignación se resolverá mediante sorteo.

Calendario y entregables

Instancia	Fecha	Entrega esperada
Avance	Miércoles 27 de mayo de 2026	Documento de máximo 6 páginas con pregunta de investigación, fuente y contexto de los datos, descripción preliminar, tratamiento inicial de datos faltantes o codificaciones especiales, análisis exploratorio, plan de modelamiento y enlace al repositorio público de GitHub .
Informe final	Lunes 15 de junio de 2026	Documento de máximo 15 páginas de cuerpo principal, sin contar bibliografía, anexos ni código. Debe contener el análisis completo, resultados, diagnósticos, discusión, recomendación final y enlace al repositorio público de GitHub .
Presentación final	Lunes 15 de junio de 2026	Presentación oral de 8 a 10 minutos por grupo, más preguntas. Deben participar todos los integrantes.

Todo el código debe estar disponible en un repositorio público de [GitHub](#). Se acepta trabajar en `.R`, `.Rmd`, `.qmd` u otro formato reproducible equivalente. El repositorio debe permitir reconstruir las tablas, figuras y modelos reportados, o indicar claramente cualquier paso manual que no pueda automatizarse. No es necesario subir bases pesadas si la fuente oficial restringe o dificulta su distribución, pero el repositorio debe incluir instrucciones claras para descargarlas o ubicarlas.

El repositorio debe contener, como **mínimo**, un archivo `README` con instrucciones de reproducción, el código principal del análisis, los datos usados o instrucciones para obtenerlos, los archivos fuente del informe cuando corresponda, y un registro de paquetes o versiones utilizadas por ejemplo mediante `sessionInfo()`.

Trabajo esperado

Cada grupo debe construir una narrativa estadística completa. Como **mínimo**, el informe final debe contener:

1. Contexto del problema, fuente de datos, unidad de observación, variable respuesta, predictores candidatos, tamaño muestral, presencia de datos faltantes y motivación de la pregunta.
2. Declaración explícita del objetivo principal del análisis: descriptivo o predictivo. Si el objetivo es descriptivo, el énfasis debe estar en interpretación, incertidumbre y limitaciones; si es predictivo, debe incluir una evaluación razonable del desempeño fuera de muestra o de predicción.
3. Limpieza y preparación de datos: codificación de variables, tratamiento de datos faltantes, justificación de filtros, transformaciones iniciales y definición de la muestra analizada.
4. Análisis exploratorio con tablas o gráficos que conecten directamente con la pregunta.
5. Un conjunto justificado de modelos lineales candidatos. El número de modelos debe responder a la pregunta, a la estructura de los datos y a las comparaciones necesarias; por ejemplo, modelos anidados, inclusión o exclusión de grupos de variables, interacciones, dummies o transformaciones cuando corresponda. No basta con ajustar modelos por catálogo: cada modelo debe responder a una hipótesis, comparación o decisión de modelamiento.
6. Evaluación de ajuste e inferencia: interpretación de coeficientes, pruebas relevantes, R^2 , R_a^2 , intervalos de confianza y, cuando el objetivo sea predictivo, intervalos o evaluación de predicción.
7. Diagnóstico del modelo: linealidad, residuos versus valores ajustados, normalidad de residuos cuando sea pertinente para la inferencia, colinealidad, heterocedasticidad, autocorrelación si hay estructura temporal o espacial relevante, y observaciones influyentes.
8. Análisis de sensibilidad: explicar si las conclusiones cambian ante decisiones razonables de limpieza, transformación, selección de variables o retiro justificado de casos influyentes.
9. Conclusión contextual: responder la pregunta inicial y proponer una acción, decisión, advertencia o recomendación coherente con el alcance de los datos.

El proyecto debe estar centrado en regresión lineal. Otros modelos, incluyendo modelos de aprendizaje automático, regularización, árboles, modelos no paramétricos u otros enfoques predictivos, podrán aparecer sólo como referencia o comparación secundaria con el modelo lineal propuesto. No reemplazan la interpretación, inferencia y diagnóstico de regresión lineal. Tampoco se exigirá causalidad; cualquier afirmación causal debe formularse con cautela y sólo si el diseño, la fuente y los supuestos lo permiten.

Evidencia mínima esperada

El avance debe incluir una ficha inicial del conjunto de datos. Esta ficha debe indicar fuente, contexto, unidad de observación, variable dependiente numérica, predictores candidatos, tamaño muestral, datos faltantes y posibles dificultades del análisis, tales como valores atípicos, colinealidad, respuesta asimétrica, codificaciones especiales o dependencia temporal.

El informe final debe tener una estructura ordenada: pregunta y contexto; datos y preparación; análisis exploratorio; modelos candidatos; diagnóstico y selección; interpretación de resultados; recomendación o acción propuesta; limitaciones; bibliografía; y anexos cuando sean necesarios. Los anexos pueden contener código, tablas extensas, diccionario de variables, diagnósticos adicionales o resultados secundarios, y no cuentan dentro del límite de páginas del cuerpo principal.

La presentación debe concentrarse en la historia estadística del trabajo: pregunta, datos, decisiones de modelamiento, evidencia principal, limitaciones y recomendación. No se espera una descripción extensa del código ni de cada paso menor de limpieza.

Rúbrica de evaluación

El avance, el informe final y la presentación final se calificarán cada uno en base 60. Luego, las notas convertidas a escala 1–7 se ponderarán según los pesos del proyecto: avance 20 %, informe final 45 % y presentación final 35 %. En cada criterio, el nivel intermedio se asigna cuando el trabajo cumple de manera suficiente pero con debilidades corregibles; los puntajes dentro de cada fila se distribuirán de acuerdo con la calidad observada.

Avance: 60 puntos

Criterio	Pts.	Nivel alto	Nivel medio	Nivel insuficiente
Pregunta y contexto	12	Pregunta clara, abordable con regresión lineal y conectada con una decisión o interpretación de fondo.	Pregunta comprensible, pero con alcance amplio, motivación incompleta o conexión débil con el contexto.	Pregunta vaga, no modelable con los datos o desconectada de la fuente.
Fuente, datos y ética	12	Fuente fiable, unidad de observación, variables principales y consideraciones éticas bien descritas.	Fuente identificada, pero faltan detalles sobre unidad, cobertura, limitaciones o uso responsable.	Fuente poco clara, sin contexto suficiente o con riesgos éticos no discutidos.
Limpieza y EDA	16	Limpieza inicial justificada, faltantes y codificaciones revisados, y EDA directamente ligado a la pregunta.	Limpieza o EDA parcial, con decisiones razonables pero poco justificadas.	Limpieza ausente o meramente mecánica; EDA desconectado de la pregunta.
Plan de modelos	14	Propone modelos lineales candidatos coherentes, comparaciones pertinentes y diagnósticos previstos.	Plan general correcto, pero con poca justificación de variables, transformaciones o comparaciones.	Plan impreciso o centrado en técnicas fuera del foco del curso.
Claridad y reproducibilidad	6	Documento claro y repositorio público funcional con estructura inicial reproducible.	Documento entendible, pero repositorio incompleto o poco ordenado.	Entrega difícil de seguir o sin repositorio público usable.

Informe final: 60 puntos

Criterio	Pts.	Nivel alto	Nivel medio	Nivel insuficiente
Modelación e inferencia	16	Modelos lineales bien especificados, inferencia correcta y comparaciones justificadas según la pregunta.	Modelación adecuada, con errores menores de interpretación o justificación incompleta.	Modelos mal especificados, inferencia incorrecta o ausencia de comparación relevante.
Diagnóstico y remedios	14	Revisa supuestos, colinealidad, heterocedasticidad, autocorrelación e influencia según corresponda, y propone remedios razonables.	Diagnóstico parcial o remedios poco desarrollados, pero reconoce problemas principales.	Diagnóstico superficial, ignorado o sin relación con las conclusiones.
Selección, validación y predicción	10	Selección o validación coherente; evalúa ajuste, predicción e incertidumbre cuando corresponde.	Usa criterios de ajuste o validación, pero con conexión limitada con el objetivo.	Selección arbitraria o sin evaluación del desempeño del modelo.
Interpretación y acción propuesta	10	Conclusiones responden la pregunta, reconocen limitaciones y derivan una recomendación defendible.	Conclusiones razonables, pero con limitaciones poco discutidas o recomendación genérica.	Conclusiones no se siguen del análisis o exceden el alcance de los datos.
Presentación formal y reproducibilidad	10	Informe claro, bien escrito, con visualizaciones legibles, citas completas y repositorio público reproducible.	Informe comprensible, con problemas menores de forma, citas o reproducción.	Informe desordenado, sin citas adecuadas o con código no reproducible.

Presentación final: 60 puntos

Criterio	Pts.	Nivel alto	Nivel medio	Nivel insuficiente
Claridad narrativa	16	Explica pregunta, datos, estrategia y conclusiones con una historia ordenada y convincente.	Presentación entendible, pero con saltos narrativos o exceso de detalles secundarios.	Narrativa confusa o sin conexión entre problema, modelo y conclusión.
Solidez técnica	20	Defiende decisiones de modelamiento, inferencia y diagnóstico con precisión.	Responde lo principal, pero con vacíos o imprecisiones técnicas.	Evidencia confusión importante sobre el modelo o sus supuestos.
Visualizaciones y tiempo	12	Visualizaciones legibles y pertinentes; respeta 8 a 10 minutos.	Visualizaciones útiles pero recargadas, o manejo de tiempo irregular.	Visualizaciones poco legibles o presentación fuera del tiempo asignado.
Respuestas y participación	12	Todos participan y responden preguntas mostrando dominio del trabajo.	Participación desigual, aunque el grupo responde la mayor parte de las preguntas.	Participación muy concentrada o respuestas insuficientes.

Criterios formales

- El avance y el informe final deben estar escritos de manera clara, con tablas y figuras numeradas cuando corresponda.
- El avance y el informe final deben elaborarse en $\text{\LaTeX}$ y entregarse en formato PDF.
- Toda fuente externa debe citarse. Los datos deben venir de una fuente oficial, un artículo o una institución identificable.
- El informe final debe incluir bibliografía y enlace al repositorio público de [GitHub](#).
- Las figuras deben tener títulos o leyendas interpretables; no se aceptarán salidas extensas de software sin explicación.
- Los anexos pueden contener detalles adicionales, pero no reemplazan el análisis principal ni la discusión de resultados.
- El uso de herramientas externas, incluyendo inteligencia artificial, foros, tutoriales o código adaptado desde otras fuentes, debe declararse brevemente cuando haya influido en el análisis, redacción o programación.
- La colaboración entre grupos debe limitarse a dudas generales de programación o comprensión de datos. El análisis, redacción, código y presentación deben ser propios de cada grupo.

Producto final esperado

Al terminar el proyecto, cada grupo debería ser capaz de explicar qué pregunta abordó, por qué los datos son apropiados, qué decisiones de limpieza fueron necesarias, qué modelos lineales se compararon, cuáles supuestos fueron razonables o problemáticos, cuán estables son las conclusiones y qué acción o recomendación se desprende del análisis.

Propuesta de conjuntos de datos propios

Los grupos podrán proponer un conjunto de datos propio. En ese caso, antes de usar los datos, el grupo debe mostrar la base o una muestra representativa, describir la fuente, explicar el contexto del problema, indicar qué variables contiene y proponer cuál sería la variable dependiente numérica. También debe aclarar si existen restricciones de confidencialidad, anonimización o permiso de uso.

Cada caso será analizado individualmente. Para ser aprobado, el conjunto de datos debe tener una pregunta abordable con regresión lineal, una variable respuesta numérica no binaria, suficientes observaciones y predictores pertinentes para construir, comparar y diagnosticar modelos dentro de los contenidos del curso.

Conjuntos de datos disponibles

Todos los conjuntos de datos disponibles tienen al menos una variable dependiente numérica. No se aceptará como objetivo principal una respuesta binaria. La selección final de variables, transformaciones y muestra analítica debe quedar justificada en el informe.

1. **Body Dimensions.** Mediciones antropométricas de personas adultas, distribuidas por OpenIntro a partir del trabajo de Heinz et al. [1, 2]. La unidad de observación es una persona. Las variables registradas incluyen diámetros corporales, perímetros, edad, sexo, peso y estatura. Variables dependientes numéricas disponibles: peso y estatura. Descarga: <https://www.openintro.org/data/csv/bdims.csv>.
2. **Energy Efficiency.** Simulaciones de desempeño energético de edificios residenciales [3, 4]. La unidad de observación es una configuración de edificio. Las variables registradas son compacidad relativa, área de superficie, área de muros, área de techo, altura total, orientación, área vidriada y distribución del área vidriada. Variables dependientes numéricas: carga de calefacción y carga de enfriamiento. Descarga: <https://archive.ics.uci.edu/dataset/242/energy+efficiency>.
3. **USGS Earthquakes.** Catálogo oficial de eventos sísmicos del U.S. Geological Survey [5]. La unidad de observación es un evento sísmico registrado durante 2024 con magnitud al menos 4. Las variables registradas incluyen fecha y hora, latitud, longitud, profundidad, tipo de magnitud, número de estaciones, brecha azimutal, distancia mínima, RMS, red de reporte y lugar. Variable dependiente numérica: magnitud del evento. Descarga: <https://earthquake.usgs.gov/fdsnws/event/1/>.
4. **SAT and GPA.** Datos educacionales distribuidos por OpenIntro, originalmente recolectados por Educational Testing Service [6]. La unidad de observación es un estudiante. Las variables registradas son sexo, percentil SAT verbal, percentil SAT matemático, puntaje SAT total, promedio de notas de enseñanza media y promedio de notas del primer año de universidad. Variables dependientes numéricas disponibles: promedio de notas del primer año y promedio de notas de enseñanza media. Descarga: <https://www.openintro.org/data/csv/satgpa.csv>.
5. **Real Estate Valuation.** Transacciones inmobiliarias en Sindian District, New Taipei City, Taiwán [7]. La unidad de observación es una transacción. Las variables registradas son fecha de transacción, edad de la vivienda, distancia a la estación MRT más cercana, número de tiendas de conveniencia cercanas, latitud y longitud. Variable dependiente numérica: precio de la vivienda por unidad de área. Descarga: <https://archive.ics.uci.edu/dataset/477/real+estate+valuation+data+set>.
6. **Bike Sharing.** Registros del sistema Capital Bikeshare en Washington D.C. junto con variables meteorológicas y de calendario [8, 9]. La unidad de observación puede ser una hora o un día, según el

archivo usado. Las variables registradas incluyen temperatura, sensación térmica, humedad, velocidad del viento, estación del año, día laboral y condición meteorológica. Variables dependientes numéricas: número total de arriendos, número de arriendos casuales y número de arriendos registrados. Descarga: <https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset>.

7. **Forest Fires.** Registros de incendios forestales en el Parque Natural de Montesinho, Portugal [10, 11]. La unidad de observación es un incendio registrado. Las variables registradas incluyen coordenadas internas del mapa, mes, día, índices FFMC, DMC, DC e ISI, temperatura, humedad relativa, viento y lluvia. Variable dependiente numérica: área quemada, en hectáreas. Descarga: <https://archive.ics.uci.edu/dataset/162/forest+fires>.
8. **Mario Kart Auctions.** Subastas de juegos usados de Mario Kart para Nintendo Wii, recopiladas desde eBay y distribuidas por OpenIntro [12]. La unidad de observación es una subasta. Las variables registradas incluyen duración de la subasta, número de ofertas, condición del producto, precio inicial, costo de envío, evaluación del vendedor, uso de foto de stock, inclusión de volante y precio total. Variable dependiente numérica: precio total de venta. Descarga: <https://www.openintro.org/data/csv/mariokart.csv>.
9. **NHANES 2021-2023.** Encuesta oficial del CDC/NCHS con cuestionarios, examen físico y laboratorio [13]. La unidad de observación es una persona examinada. Los módulos relevantes son demografía, medidas corporales, presión arterial y colesterol total. Variables dependientes numéricas disponibles: índice de masa corporal, presión sistólica promedio, presión diastólica promedio y colesterol total. Descarga: <https://www.cdc.gov/nchs/nhanes/continuousnhanes/default.aspx?Cycle=2021-2023>.
10. **Seattle Building Energy Benchmarking.** Datos oficiales de la ciudad de Seattle sobre consumo energético y emisiones de edificios [14]. La unidad de observación es un edificio o propiedad reportada. Las variables registradas incluyen año de construcción, superficie total, número de pisos, número de edificios y variables de uso energético. Variables dependientes numéricas disponibles: intensidad de uso energético, emisiones totales de gases de efecto invernadero y puntaje ENERGY STAR. Descarga: https://data.seattle.gov/Built-Environment/Building-Energy-Benchmarking-Data-2015-Present/teqw-tu6e/about_data.
11. **EPA Fuel Economy.** Datos oficiales de economía de combustible para vehículos publicados por el U.S. Department of Energy y la EPA [15]. La unidad de observación es una versión de vehículo. Las variables registradas incluyen año, cilindros, desplazamiento, tipo de combustible, rendimiento en ciudad, rendimiento en carretera, rendimiento combinado y emisiones de CO₂. Variables dependientes numéricas disponibles: rendimiento combinado en millas por galón y emisiones de CO₂ por milla. Descarga: <https://www.fueleconomy.gov/feg/download.shtml>.
12. **Lending Club Loans.** Préstamos personales distribuidos por OpenIntro a partir de registros de Lending Club [16]. La unidad de observación es un préstamo. Las variables registradas incluyen monto solicitado, tasa de interés, plazo, ingreso anual declarado, razón deuda-ingreso, historial crediticio, número de consultas recientes, grado del préstamo y propósito. Variables dependientes numéricas disponibles: tasa de interés y monto del préstamo. Descarga: https://www.openintro.org/data/csv/loans_full_schema.csv.

Referencias

- [1] Heinz, G., Peterson, L. J., Johnson, R. W., and Kerk, C. J. (2003). Exploring relationships in body dimensions. *Journal of Statistics Education*, 11(2).
- [2] OpenIntro. (2026). Body dimensions data. <https://www.openintro.org/data/index.php?data=bdims>
- [3] Tsanas, A., and Xifara, A. (2012). Accurate quantitative estimation of energy performance of residential buildings using statistical machine learning tools. *Energy and Buildings*, 49, 560–567.

- [4] UCI Machine Learning Repository. (2012). Energy Efficiency Dataset. <https://archive.ics.uci.edu/dataset/242/energy+efficiency>
- [5] U.S. Geological Survey. (2026). Earthquake Catalog API. <https://earthquake.usgs.gov/fdsnws/event/1/>
- [6] OpenIntro. (2026). SAT and GPA data. <https://www.openintro.org/data/index.php?data=satgpa>
- [7] UCI Machine Learning Repository. (2018). Real Estate Valuation Dataset. <https://archive.ics.uci.edu/dataset/477/real+estate+valuation+data+set>
- [8] Fanaee-T, H., and Gama, J. (2014). Event labeling combining ensemble detectors and background knowledge. *Progress in Artificial Intelligence*, 2, 113–127.
- [9] UCI Machine Learning Repository. (2013). Bike Sharing Dataset. <https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset>
- [10] Cortez, P., and Morais, A. (2007). A data mining approach to predict forest fires using meteorological data. In *Proceedings of the 13th EPIA 2007*.
- [11] UCI Machine Learning Repository. (2008). Forest Fires Dataset. <https://archive.ics.uci.edu/dataset/162/forest+fires>
- [12] OpenIntro. (2026). Mario Kart auction data. <https://www.openintro.org/data/index.php?data=mariokart>
- [13] National Center for Health Statistics. (2023). National Health and Nutrition Examination Survey, 2021–2023. <https://wwwn.cdc.gov/nchs/nhanes/continuousnhanes/default.aspx?Cycle=2021-2023>
- [14] City of Seattle. (2026). Building Energy Benchmarking Data, 2015–Present. https://data.seattle.gov/Built-Environment/Building-Energy-Benchmarking-Data-2015-Present/teqw-tu6e/about_data
- [15] U.S. Department of Energy and U.S. Environmental Protection Agency. (2026). Fuel economy data. <https://www.fueleconomy.gov/feg/download.shtml>
- [16] OpenIntro. (2026). Lending Club loans full schema. https://www.openintro.org/data/index.php?data=loans_full_schema